
Maintenance Prédicative Industrielle par Apprentissage Automatique

Analyse du Dataset AI4I 2020

Thomas Fallouh^a, Etienne Lopez-Vilesy^a

^aDépartement Informatique, Filière FISA, Branche IAD, Université de Technologie de Compiègne (UTC)

AI28 Groupe 9 ■ Juin 2026

1. Analyse Exploratoire des Données (AED)
2. Prétraitement des données
3. Modélisation
4. Optimisation & Hyper-optimisation
5. Résultats & Évaluation
6. Conclusion

Contexte & Problématique

Dataset AI4I 2020 (UCI)

- **10 000 observations**, 12 variables
- 5 capteurs numériques + qualité pièce (L/M/H)
- 6 cibles binaires : 5 modes de panne + flag global
- Aucune valeur manquante

Enjeu

Détecter les 5 modes de panne (3.6 % des données) dans un contexte fortement déséquilibré.


Déséquilibre extrême

Classe	Effectif	Proportion
No failure	9 643	96.43 %
HDF	106	1.06 %
OSF	98	0.98 %
PWF	83	0.83 %
TWF	42	0.42 %
RNF	28	0.28 %

Conséquence

Accuracy écartée (96.4 % sans détecter une panne) au profit du **MCC** et du **F1-macro**.

1. AED : Analyse Univariée




Observations

- 1 normale (torque), 2 quasi-normales (`air_temp`, `process_temp`)
- `rot_speed` : **log-normale** (skewness 1.99, kurtosis 7.39) ; régimes extrêmes (max 2886 rpm) propices aux pannes
- `tool_wear` : **uniforme** (kurtosis -1.17, usure linéaire de 0 à 253 min)

Qualité pièce

type déséquilibrée : L 60 % / M 30 % / H 10 % (réalité industrielle).

1. AED : Distribution de la Cible



Déséquilibre hétérogène


Cible	Taux +	Ratio -/+
HDF	1.15 %	86:1
OSF	0.98 %	101:1
PWF	0.95 %	104:1
TWF	0.46 %	216:1
RNF	0.19 %	526:1

RNF (526:1) dépasse le seuil d'un signal fiable.

Co-occurrence

Sur 348 défaillances : **93.1 %** n'impliquent qu'une seule sous-panne $\Rightarrow$ encodage **multi-classe** (6 classes) justifié.

1. AED : Corrélations bivariées



Multicolinéarité entre features


- air_temp/process_temp : $r = +0.88$ (redondance thermique)
- rot_speed/torque : $r = -0.88$: contrainte physique $P = \omega \cdot \tau$ (pas une redondance)

Features → cibles : faibles

- Toutes corrélations $< |0.20|$
- Signature d'une **structure à seuil** : plusieurs conditions réunies simultanément, pas linéairement

Matrice de corrélation de Pearson.

1. AED : Clusters de pannes



Localisation par type de panne

- **HDF** : couples modérés + températures élevées
- **OSF** : fort couple + vitesse réduite
- **PWF** : extrêmes de puissance
- **TWF** : usure outil élevée (`tool_wear`)
- **RNF** : diffus, sans structure

Bilan de l'AED

Frontières **non-linéaires** $\Rightarrow$ SVM-RBF / méthodes d'ensemble. RegLog reléguée au rôle de baseline.

2. Prétraitement des Données

Pipeline commun (P1 & P2)

- Suppression des identifiants
- Correction de 9 incohérences (machine_failure=1 sans sous-panne → RNF)
- Cible **multi-classe** (priorité TWF>HDF>PWF>OSF>RNF)
- One-hot de type ; **MinMaxScaler** (fit train)
- Split stratifié 80/20

Gestion du déséquilibre

- **SMOTE** écarté : RNF aléatoire, aucun cluster à interpoler
- class_weight testé puis **abandonné** (cf. ablation)

Feature engineering P2 (+4)

Formule	Sens physique
$\text{power} = \text{rot_speed} \times \text{torque}$	Puissance
$\text{power_wear} = \text{power} \times \text{tool_wear}$	Effort $\times$ usure
$\text{temp_diff} = \text{process_temp} - \text{air_temp}$	Dissipation thermique (HDF)
$\text{temp_power} = \text{temp_diff} / \text{power}$	Ratio thermo-mécanique

Total : 8 (P1) → 12 (P2) features.

3. Modélisation : 6 modèles

Modèles testés (complexité croissante) & formule clé

Modèle	Principe / formule clé	Rôle
Rég. logistique	Softmax $\hat{p}(y=k x) = e^{w_k^\top x} / \sum_j e^{w_j^\top x}$	Baseline linéaire
KNN	Vote des k voisins (Minkowski)	Géométrie locale
SVM-RBF	Marge max., noyau $K(x, x') = e^{-\gamma \ x - x'\ ^2}$	Non-linéarité à noyau
Forêt aléatoire	Bagging d'arbres CART, $m = \sqrt{p}$ features/nœud	Décorrélation, robustesse
XGBoost	Boosting gradient $F_t = F_{t-1} + \eta h_t$	Interactions fines
AdaBoost	$F = \text{sign}(\sum_t \alpha_t h_t)$, repondération	Cas difficiles

Protocole commun

Entraînement sur **P2**, sans pondération. Sélection par **F1-macro** en CV stratifiée 5-folds ; évaluation finale sur le test par **MCC**.

4. Optimisation : Fonctions objectif

Entropie croisée (RegLog, XGBoost)

$$\mathcal{L}_{\text{CE}} = -\frac{1}{n} \sum_i \sum_k y_{ik} \log \hat{p}_{ik} + \frac{\lambda}{2} \|w\|^2$$

Régularisation L2 → stabilise les coefficients colinéaires.

Hinge : marge souple (SVM)

$$\mathcal{L}_{\text{hinge}} = \sum_i \max(0, 1 - y_i f(x_i)) + \frac{1}{2C} \|w\|^2$$

Optimise une géométrie, pas de probabilités.

Impureté de Gini : CART (forêt)

$$G(t) = 1 - \sum_k p_k^2$$

Minimisée à chaque nœud par l'algorithme **CART** (coupe binaire gloutonne).

Perte exponentielle (AdaBoost)

$$\mathcal{L}_{\text{exp}} = \sum_i e^{-y_i F(x_i)}$$

Repondère fortement les exemples mal classés.

5. Hyper-optimisation des Paramètres

Protocole

- **Optuna** (TPE, bayésien) pour tous les modèles
- CV stratifiée 5-folds, métrique **F1-macro**

Meilleurs paramètres

Modèle	HP retenus
Rég. logistique	$C \approx 100$, newton-cg
KNN	$k=1$, Manhattan
Forêt aléatoire	$T=100$ (baseline)
SVM-RBF	$C=62$, $\gamma=\text{scale}$
XGBoost	$T=100$ (baseline)
AdaBoost	$T=236$, lr 1.11, prof. 5

Saturation observée

Pour **RF** et **XGBoost**, le modèle Optuna est $\leq$ baseline : c'est le baseline qui est conservé. Le plafond expressif de P2 est atteint.

Lecture

Le $k=1$ de KNN (mémorisation) et le C élevé de RegLog (régularisation quasi nulle) signalent les limites structurelles de ces modèles.

Comprendre les Métriques : MCC & F1-macro

F1-macro

$$F1_k = \frac{2 P_k R_k}{P_k + R_k}, \quad F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k$$

Moyenne **non pondérée** des F1 par classe : chaque classe pèse autant, donc les pannes rares comptent à égalité avec *No failure*.

Pourquoi pas l'accuracy ?

Un modèle « tout No failure » atteint 96.4 % d'accuracy sans détecter une seule panne : métrique trompeuse.

MCC (Matthews)

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}}$$

Corrélation entre prédictions et vérité, $\in [-1, 1]$: **1** = parfait, **0** = aléatoire. N'est élevé que si **toutes** les classes sont bien prédites $\Rightarrow$ robuste au déséquilibre.

Notre choix

F1-macro pour la sélection (CV), **MCC** comme métrique de classement final.

6. Résultats : Comparaison des modèles

Performances test (P2, sans class_weight), triées par MCC

Modèle	MCC	F1-m.	Préc.(w)	Rapp.(w)	T.entr.	T.préd.
Forêt aléatoire	84.2 %	63.8 %	98.3 %	98.9 %	0.45	0.06
AdaBoost	80.8 %	61.9 %	98.1 %	98.8 %	7.86	2.17
XGBoost	80.1 %	61.2 %	98.0 %	98.7 %	0.94	0.03
SVM-RBF	67.1 %	52.3 %	97.2 %	98.0 %	0.62	2.72
Rég. logistique	65.6 %	52.9 %	97.2 %	97.9 %	0.35	3.46
KNN	44.2 %	43.2 %	96.2 %	96.5 %	0.03	0.08

T.entr. / T.préd. en secondes.

Ensembles

+18.6 pts MCC vs. baseline. Le bagging décorrèle les variables colinéaires.

SVM $\approx$ RegLog

Le noyau RBF n'apporte pas de gain : frontières trop localisées.

KNN ($k=1$)

Mémorisation pure, ne généralise pas en 12 dimensions.

6. Résultats : Ablation class_weight

Avec vs. sans pondération

Modèle	Avec	Sans (retenu)
Forêt aléatoire	75.5 %	84.2 %
Rég. logistique	24.5 %	65.6 %
SVM-RBF	32.7 %	67.1 %

MCC avec / sans class_weight="balanced".


Résultat notable

Contrairement à l'intuition, la pondération **dégrade** le MCC : -8.7 pts (RF), -41.1 pts (RegLog), -34.4 pts (SVM).

Explication

Le poids ≈ 526 attribué à RNF force les modèles à mémoriser un signal **purement aléatoire** : sur-apprentissage sur du bruit.

6. Évaluation par Classe & Modèle Retenu



Lecture par classe

- **OSF, HDF, PWF** bien détectées grâce aux features P2
- **TWF** (8 ex.) et **RNF** (6 ex.) : rappel nul, effectif insuffisant : RNF aléatoire, TWF trop rare

Modèle retenu : Forêt Aléatoire

MCC **84.2 %**, prédiction **0.06 s**. XGBoost valide mais inférieur sur classes rares ; AdaBoost trop lent (2.17 s).

Matrice de confusion normalisée (forêt aléatoire).

Conclusion

Résultats clés

- **MCC 84.2 %** (forêt aléatoire), +18.6 pts sur la baseline linéaire
- Le feature engineering P2 est **décisif** pour les classes minoritaires
- `class_weight` **dégrade** les performances : amplifier RNF revient à mémoriser du bruit
- Saturation RF/XGBoost : plafond expressif de P2 atteint

Limites & Perspectives

- TWF et RNF (< 35 ex.) **imprévisibles**
- Dataset **synthétique**
- Pistes : plus de données rares, **réseaux de neurones**

Bilan

La forêt aléatoire sans pondération, entraînée sur P2, constitue la solution la plus robuste pour ce problème de maintenance prédictive multi-classe.

Références

- [1] S. Matzka, *Explainable AI for Predictive Maintenance Applications*, IEEE AI4I 2020. Dataset UCI ML Repository.
- [2] T. Akiba et al., *Optuna: A Next-generation Hyperparameter Optimization Framework*, KDD 2019.
- [3] D.M.W. Powers, *Evaluation: From Precision, Recall and F-Score to ROC...*, JMLR 2011.

Merci de votre attention

Thomas Fallouh ■ Etienne Lopez-Vilesy

`thomas.fallouh@etu.utc.fr` `etienne.lopez-vilesy@etu.utc.fr`